

ENTREGA 2: Clasificación Taxonómica, Variantes, Anotación y Variantes de Interés

Presentado por: Andrea Arredondo Restrepo, Sofía Betancur Álvarez, Mariana Gutiérrez Tamayo, María José Montoya Cuartas.

Grupo: Bioamigas.

1. Clasificación taxonómica.

• Evolucionado 1:

Durante el proceso de mapeo de los reads contra el genoma ancestral ensamblado para la primera entrega del proyecto, la mayoría de los fragmentos fueron mapeados correctamente, pero solo **1,516** lecturas no lograron alinearse al genoma ancestral de referencia. Esta pequeña cantidad de lecturas sin mapear puede atribuirse a varios factores, como reads de baja calidad, diferencias biológicas entre la muestra y el genoma de referencia (inserciones, deleciones o mutaciones) e incluso regiones repetitivas difíciles de alinear. Por esta razón, se llevó a cabo la clasificación taxonómica de las lecturas no mapeadas, con el fin de identificar si correspondían a otros organismos o especies contaminantes, ya que esto permite conocer información valiosa sobre la calidad del experimento, la pureza de la muestra y la presencia de elementos genéticos adicionales.

Para lo anterior, se utilizaron las herramientas como *Kraken2* la cual sirve para identificar de forma rápida y precisa los organismos presentes en la muestra de ADN, y también se empleó *Bracken* que es una herramienta complementaria a *Kraken2* que permite estimar con mayor precisión la abundancia de especies a partir de los resultados de clasificación taxonómica obtenidos con la herramienta ya descrita y finalmente se empleó *Krona*, que es una herramienta que permite visualizar los resultados que se obtienen con *Kraken2* y con *Bracken*, puesto que los archivos generados por estas dos herramientas son las entradas para *Krona*.




Figura 1. Resultado de la distribución jerárquica obtenida con *kraken2* visualizado en *Krona* para el organismo evolucionado 1.

Una vez realizada la clasificación taxonómica, en la **figura 1** se puede observar la distribución jerárquica obtenida con *Kraken2* donde se obtuvo que el **87.6%** de todas las lecturas fueron asignadas a algún taxon y el **12.4%** se quedaron sin clasificar. A continuación, en la **tabla 1** se presentan los resultados más relevantes obtenidos de la clasificación taxonómica para el organismo evolucionado 1, donde se resumen los principales taxones detectados junto con su nivel jerárquico y porcentaje de abundancia estimado por *Bracken*.

ENTREGA 2: Clasificación Taxonómica, Variantes, Anotación y Variantes de Interés

Tabla 1. Resultados más relevantes de la clasificación taxonómica para el organismo evolucionado 1. **Elaborado por:** María José Montoya Cuartas.

CLASIFICACIÓN TAXONOMICA ORGANISMO EVOLUCIONADO 1							
DOMINIO	FILO	CLASE	ORDEN	FAMILIA	GÉNERO	ESPECIE	% ABUNDANCIA CON BRACKEN
Bacteria	Proteobacteria	Gamma-proteobacteria	Enterobacterales	Enterobacteriaceae	<i>Escherichia</i>	<i>Escherichia Coli</i>	92.46
Bacteria	Proteobacteria	Gamma-proteobacteria	Enterobacterales	Enterobacteriaceae	<i>Salmonella</i>	<i>Salmonella entérica</i>	0,15
Bacteria	Actinobacteria	Actinobacteria	Propionibacteriales	Propionibacteriaceae	<i>Cutibacterium</i>	<i>Cutibacterium acnes</i>	1,05
Bacteria	Firmicutes	Bacili	Bacillales	Staphylococcaceae	<i>Staphylococcus</i>	<i>Staphylococcus epidermis</i>	0,15
Eukaryota	Chordata	Mammalia	Primates	Homonidae	<i>Homo</i>	<i>Homo sapiens</i>	4,97

En la clasificación taxonómica de las lecturas no mapeadas se observaron que los dominios más predominantes son Bacteria y Eukaryota, siendo el primero el más representativo. Según el resultado obtenido con *Bracken* y reportado en la **tabla 1**, la especie más abundante correspondió a *Escherichia coli*, ya que es común que en los análisis de evolución experimental existan pequeñas diferencias acumuladas en las especies descendientes, generando que algunas lecturas del genoma evolucionado no se alineen exactamente al ancestro, pero las bases de datos taxonómicas sí pueden asignar esos fragmentos a especies cercanas debido a la similitud parcial conservada. Esto se debe a que la herramienta *Kraken2* opera mediante un análisis de *k-mers*, es decir, subsecuencias cortas de ADN de longitud *k*, y lo que hacen estos clasificadores taxonómicos es comparar la composición de esos *k-mers* con una base de datos más amplia que contiene muchos genomas, permitiendo así que el clasificador asigne la lectura a esta especie, lo cual explica su presencia en la clasificación taxonómica a pesar de provenir de lecturas no mapeadas (Wood & Salzberg, 2014).

En la clasificación taxonómica, también se detectó la presencia de *Salmonella enterica* en una baja proporción tal como se registra en la **tabla 1**, sin embargo, es interesante analizar este resultado, ya que es una bacteria que pertenece a la misma familia de *Escherichia coli* y comparten similitud genómica que se puede evidenciar por ejemplo en la capacidad que tienen ambas en causar enfermedades gastrointestinales. Esta relación entre ambas bacterias se puede observar en la **figura 2**, la cual corresponde a la distribución equitativa entre estas especies, además, en la **figura 3**, se puede observar el análisis global del conjunto de lecturas donde aproximadamente el **30%** de la abundancia total bacteriana es conformada por estas especies, junto con otros géneros como *Staphylococcus*, *Streptococcus* y *Acinetobacter*. Este patrón confirma que la familia enterobacteriaceae fue dominante entre la clase de Gammaproteobacteria, mientras que el resto de las lecturas se distribuyeron en clases como Bacili y Actinobacteria.

Aunque la detección de *S. Entérica* fue en baja proporción, es relevante considerar que su presencia puede sugerir que algunas lecturas de *E. coli* pudieron ser parcialmente asignadas al género *Salmonella* debido a la similitud estructural de sus secuencias. Esta alta similitud es un reflejo directo de la estrecha relación filogenética entre ambos géneros, los cuales según la literatura divergieron de un ancestro común en un pasado evolutivo reciente (Ochman & Jones, 2000). Esto último evidencia la naturaleza conservada de ciertas regiones genómicas y las limitaciones que pueden tener los métodos de clasificación basados en *K-mers*.

ENTREGA 2: Clasificación Taxonómica, Variantes, Anotación y Variantes de Interés



Figura 2 y 3 (en ese orden). Distribución equitativa entre especies de la familia Enterobacteriaceae. Abundancia bacteriana de la familia Enterobacteriaceae.

En segundo lugar, se identificaron secuencias asignadas a *Homo sapiens* debido a que **4,97%** de las lecturas fueron asignadas a esta especie. Este hallazgo se puede interpretar como una posible contaminación de origen humano que probablemente pudo ser introducida durante la manipulación experimental como por ejemplo en la extracción, preparación del ADN o reactivos contaminados. Este tipo de contaminación es frecuente en experimentos de secuenciación sobre todo si las muestras bacterianas no fueron manipuladas en condiciones estériles estrictas. Además, también es importante resaltar que se detectaron lecturas correspondientes a *Cutibacterium acnes* y *Staphylococcus epidermis*, los cuales son contaminantes ubicuos reportados en el ambiente de laboratorio y comunes en el microbiota de la piel humana (Salter et al., 2014). La presencia de estas bacterias podría respaldar la hipótesis de que su origen proviene del ambiente del laboratorio, ya que ambas especies suelen encontrarse en la superficie cutánea, instrumentos o guantes demostrando así la alta sensibilidad de las herramientas de clasificación taxonómica, puesto que son capaces de detectar restos mínimos de ADN exógeno.

Finalmente, se identificaron lecturas asignadas a *Escherichia virus T1*, correspondiente al **0,3 %** del total de lecturas clasificadas. El virus T1 es un bacteriófago que infecta a *Escherichia coli* y se caracteriza por poseer un mecanismo eficiente para superar las barreras de restricción del hospedador, como la metilación de su ADN (Wagner et al., 1983). Además, los bacteriófagos desempeñan un papel importante en la evolución y la variabilidad genética de las bacterias, al actuar como vehículos de transferencia horizontal de genes y favorecer la adquisición de nuevas funciones adaptativas.

• **Evolucionado 2:**

En la primera fase del proyecto se obtuvo que la mayoría de las lecturas correspondientes al organismo evolucionado 2 fueron mapeadas correctamente pero solo **30,904** lecturas no presentaron coincidencia significativa, es por eso que a este organismo se le realizó el mismo proceso descrito anteriormente para el organismo evolucionado 1.

En la clasificación taxonómica realizada con *Kraken2* se obtuvo que el **98.1%** de las lecturas fueron asignadas a algún taxón y que el **1.9%** se quedaron sin clasificar tal como se observa en la **figura 4**. Además,

ENTREGA 2: Clasificación Taxonómica, Variantes, Anotación y Variantes de Interés

también se identificó que los organismos más representativos son los virus destacándose principalmente el *Escherichia virus T1* que a diferencia del organismo evolucionado 1; este virus es el organismo que más porcentaje de abundancia abarca en el organismo evolucionado 2 puesto que aproximadamente el **95%** de las lecturas corresponden a este organismo. En menor proporción se detectaron organismos del dominio Bacteria y del dominio Eukarya.




Figura 4. Resultado de la distribución jerárquica obtenida con *kraken2* visualizado en *Krona* para el organismo evolucionado 2.

Ahora bien, teniendo en cuenta que la mayoría de los organismos clasificados son virus, es importante comprender que la clasificación taxonómica de estos esta principalmente establecida por el Comité Internacional de Taxonomía de Virus (ICTV) y se basa en la naturaleza y estructura del genoma viral, así como su método de replicación (ICTV, s.f.). Los virus se agrupan en categorías jerárquicas similares a las de otros organismos, así como se observa en la **tabla 2** donde se presentan los 3 virus que abarcan el mayor porcentaje de lecturas.

Tabla 2. Resultados más relevantes de la clasificación taxonómica de los virus para el organismo evolucionado 2. *Elaborado por: María José Montoya Cuartas.*

CLASIFICACIÓN TAXONÓMICA PARA VIRUS DEL ORGANISMO EVOLUCIONADO 2					
ORDEN	FAMILIA	SUBFAMILIA	GÉNERO	ESPECIE	% ABUNDANCIA CON BRACKEN
Caudovirales	Siphoviridae	Tunavirinae	Tunavirus	<i>Escherichia virus T1</i>	94,9
Caudovirales	Siphoviridae	Tunavirinae	Tunavirus	<i>Escherichia virus ADB2</i>	0,79
Caudovirales	Siphoviridae	Tunavirinae	Tunavirus	<i>Shigella virus PSf-2</i>	0,18

Otros de los virus encontrados en la clasificación taxonómica fueron los bacteriófagos *Escherichia virus ADB2* (**0,79%**) y *Shigella virus PSf-2* (**0,18%**) cuya clasificación taxonómica se detalla en la **tabla 2**. La presencia de estos bacteriófagos amplía el espectro de las interacciones virales observadas en el organismo evolucionado, que en el caso del organismo 2 adquieren una dinámica más compleja en comparación con el

ENTREGA 2: Clasificación Taxonómica, Variantes, Anotación y Variantes de Interés

organismo evolucionado 1, ya que ambas especies de virus pertenecen al mismo orden y familia, y sus hospedadores filogenéticamente cercanos coexisten y son susceptibles a infección por los mismos fagos. Esto puede generar competencia entre los virus por los recursos bacterianos como la maquinaria replicativa y la energía intracelular. Esta interacción ecológica genera una presión selectiva clave en la comunidad microbiana, impulsando los procesos de coevolución fago-bacteria (Koskella & Brockhurst, 2014).

La detección simultánea de fagos que infectan a *Escherichia* y a *Shigella* refleja la estrecha relación filogenética entre ambos géneros, ya que *Shigella* se considera como un derivado evolutivo de *E. coli* (Pupo et al., 2000). Esta proximidad evolutiva, evidenciada también en la clasificación taxonómica en la **tabla 3**, permite que fagos del género *Tunavirus* reconozcan receptores de superficie similares en ambos hospedadores, lo que amplía su rango de infección y favorece procesos de coevolución y transferencia genética entre especies estrechamente relacionadas (Koskella & Brockhurst, 2014).

Tabla 3. Resultados más relevantes de la clasificación taxonómica para el organismo evolucionado 2. *Elaborado por: María José Montoya Cuartas.*

CLASIFICACIÓN TAXONOMICA ORGANISMO EVOLUCIONADO 2							
DOMINIO	FILO	CLASE	ORDEN	FAMILIA	GÉNERO	ESPECIE	% ABUNDANCIA CON BRACKEN
Bacteria	Proteobacteria	Gamma-proteobacteria	Enterobacterales	Enterobacteriaceae	<i>Escherichia</i>	<i>Escherichia Coli</i>	3.66
Bacteria	Proteobacteria	Gamma-proteobacteria	Enterobacterales	Enterobacteriaceae	<i>shigella</i>	<i>Shigella flexneri</i>	0,01
Bacteria	Actinobacteria	Actinobacteria	Micrococcales	Micrococcaceae	<i>Rothia</i>	<i>Rothia mucilaginosa</i>	0,01
Bacteria	Actinobacteria	Actinobacteria	Propionibacteriales	Propionibacteriaceae	<i>Cutibacterium</i>	<i>Cutibacterium acnes</i>	0,026
Eukaryota	Chordata	Mammalia	Primates	Homonidae	<i>Homo</i>	<i>Homo sapiens</i>	0,2

Por otra parte, en el dominio Eukarya, se detectó la presencia de la especie *Homo Sapiens*, mientras que dentro del dominio Bacteria se identificaron especies como *Cutibacterium acnes* y *Rothia mucilaginosa* cuya clasificación taxonómica se reporta en la **tabla 3** y su presencia se puede observar en la **figura 5**. Estos organismos corresponden principalmente a la microbiota humana asociada a la piel y las mucosas, tal como se describió para el organismo evolucionado 1, la detección de estos taxones puede atribuirse a contaminación por manipulación de las muestras o extracción de ADN.

En comparación con el organismo evolucionado 1, donde estos taxones también fueron detectados a excepción de la especie *Rothia mucilaginosa*, en el organismo evolucionado 2 su abundancia relativa fue menor y según la representación gráfica obtenida con *Krona*, el **33%** de las lecturas pertenecientes la clase de Actinobacteria corresponden a *Rothia mucilaginosa*, tal como se puede apreciar en la **figura 6**. Cabe mencionar que, al analizar estos resultados, es importante considerar que las herramientas *Krona* y *Bracken* pueden arrojar diferencias en los porcentajes de abundancia reportados. Esto ocurre porque *Krona* muestra proporciones relativas dentro de cada nivel taxonómico, mientras que *Bracken* calcula las abundancias corregidas de manera global sobre el total de lectura, proporcionando valores más precisos (Bracken, s.f.). Un ejemplo de esto se observa en la **figura 5**, donde se muestra un **6%** para *Homo sapiens*, mientras que en el reporte de *Bracken* y tal como se muestra en la **tabla 3**, el porcentaje de abundancia indica un **0.2%**, reflejando con mayor exactitud la baja presencia de ADN humano en la muestra.

Finalmente, es importante resaltar que el análisis taxonómico que se realizó con la herramienta *Kraken2* permitió identificar la familia Siphoviridae dentro de los virus detectados, un resultado que es coherente con

ENTREGA 2: Clasificación Taxonómica, Variantes, Anotación y Variantes de Interés

las bases de datos que emplea la herramienta como referencia. Sin embargo, es crucial resaltar que esta familia junto con Myroviridae y Podoviridae, fueron abolidas por el ICTV en su actualización de taxonomía de 2021. Esta reclasificación marcó el fin de los taxones definidos principalmente por la morfología del virión, reemplazándolos por un sistema basado en comparaciones genómicas que reflejan con mayor precisión las relaciones filogenéticas, como la actual clase Caudoviricetes (Turner et al., 2023).




Figura 5 y 6 (en ese orden). Resultado de la distribución jerárquica obtenida con bracken visualizado en krona para el organismo evolucionado 2. Distribución equitativa entre especies de la clase Actinobacteria.

En este contexto, la presencia de *Siphoviridae* en los resultados no constituye un error de la herramienta, sino una consecuencia de las bases taxonómicas utilizadas por *Kraken2*, que en este caso corresponden a la base **MiniKraken2_v2_8GB_201904**, actualizada por última vez en abril de 2019. Esto explica por qué, a pesar de que actualmente la familia a la que pertenecen los virus encontrados es Drexelviriidae, estos siguen siendo clasificados por la herramienta dentro de la familia abolida. Este hecho evidencia la naturaleza dinámica de la taxonomía viral y resalta la importancia de considerar la versión de las bases de datos al interpretar resultados bioinformáticos.

2. Variantes de interés.

Las variantes genómicas corresponden a alteraciones en la secuencia del ADN que pueden influir o no en la función del gen, y que pueden ser detectadas mediante herramientas bioinformáticas (Ardlie & Guigó, 2017). En este caso, se utilizó la herramienta *SnpEff*, la cual permite una rápida categorización de los efectos de las variantes sobre las secuencias genómicas; entonces, una vez el genoma es secuenciado la herramienta anota las variantes con base a su ubicación genómica y predice los efectos de su codificación (Cingolani et al., 2012). De esta manera, en el reporte generado con *SnpEff* se obtuvo un total de **18.445** variantes procesadas, las cuales fueron clasificadas según su impacto funcional y el tipo de cambio que generan, para determinar cuáles presentan mayor interés biológico.

De acuerdo a su nivel de impacto, las variantes clasificadas como *HIGH*, implican la pérdida completa de la función (LoF) o una alteración estructural bastante disruptiva, mientras que las que tienen un impacto *MODERATE* implican un cambio en la estructura primaria con una posible alteración funcional y las *LOW* solo cambios en la secuencia de ADN, sin una alteración significativa de la proteína. Por otra parte, las etiquetadas como *MODIFIER* únicamente derivan cambios en las regiones no codificantes o inter génicas

ENTREGA 2: Clasificación Taxonómica, Variantes, Anotación y Variantes de Interés

(Cingolani, s.f). En este caso, el mayor porcentaje de variantes (**91,206%**) corresponde a aquellas clasificadas como *MODIFIER* con un total de **195,529** variantes, las cuales generalmente no afectan directamente la función de la proteína. Sin embargo, existe un conjunto importante de variantes de impacto alto y un grupo pequeño de impacto moderado, que podría estar asociado a cambios funcionales graves. En la **figura 7** se muestra el número total de variantes por impacto.

Number of effects by impact

Type (alphabetical order)	Count	Percent
HIGH	18,487	8.623%
LOW	142	0.066%
MODERATE	223	0.104%
MODIFIER	195,529	91.206%

Number of effects by functional class

Type (alphabetical order)	Count	Percent
MISSENSE	215	59.392%
NONSENSE	5	1.381%
SILENT	142	39.227%

Figura 7 y 8 (en ese orden). Clasificación de variantes de acuerdo a su impacto. Clasificación de variantes respecto a sus efectos funcionales. Ambas imágenes tomadas del reporte generado por la herramienta *SnpEff*.

En cuanto a su efecto por funcionalidad, se tiene que pueden ser de tipo *MISSENSE*, *NONSENSE* o *SILENT*. Una mutación silenciosa ocurre cuando se produce un cambio en la secuencia de nucleótidos del ADN, pero no se altera el aminoácido que será incorporado en la proteína. En contraste, una mutación de tipo *MISSENSE* ocurre si se altera el aminoácido original, lo que puede modificar características funcionales o estructurales de la proteína cuando ocurre en un CDS; es decir, una base cambia en el ADN, provocando la sustitución de un aminoácido en la proteína y modificando el transcripto. Finalmente, una mutación *NONSENSE* convierte un codón que normalmente codifica un aminoácido en un codón de paro, deteniendo la síntesis de la proteína, pudiendo generar proteínas truncadas y no funcionales, especialmente cuando el corte ocurre lejos del codón de terminación natural (Khan Academy, s.f.).

De esta manera, de acuerdo a la **figura 8** la mayor parte de los cambios relevantes ocurre como mutaciones *MISSENSE*, con **215** y **59,392 %** del total clasificado; y aunque las mutaciones *NONSENSE*, son mucho más escasas y con una menor frecuencia, tienen un alto riesgo funcional. Por último, las mutaciones silenciosas, también están presentes en gran cantidad dentro de la clasificación, pero no alteran el aminoácido codificado. Los datos del reporte permiten concluir que la mayoría de variantes carecen de consecuencias funcionales directas; sin embargo, existe un número notable de mutaciones *HIGH* y *MISSENSE* que deben ser priorizadas en caso de análisis posteriores, ya que son las que tienen mayor probabilidad de afectar la función de los genes y la síntesis proteica.

Para el análisis de las variantes, luego de obtener el archivo generado por *SnpEff*, se filtraron de acuerdo a su impacto, obteniendo las de alto y moderado en dos archivos diferentes, sobre los cuales se realizó una depuración por calidad (mayor a 30), para luego organizarlos en orden descendente respecto a su calidad y generar dos nuevos archivos que permitieron seleccionar las 5 primeras variantes para cada impacto, tal como se observa en la **tabla 4** y la **tabla 5** respectivamente. Con base a la información obtenida en los resultados de anotación y de llamado de variantes, arrojados respectivamente por las herramientas *Prokka* y *SnpEff*, se seleccionaron las columnas de información de las tablas ya mencionadas.

En las tablas se incluyen 12 columnas que permiten describir cada variante identificada. La columna **Variant** corresponde al número asignado para organizar la información, mientras que **SEQ ID** indica la secuencia o scaffold del genoma donde se localiza la mutación; en el caso de la **tabla 5**, se observa que todas comparten el mismo nodo, lo que evidencia que las variantes se encuentran dentro del mismo scaffold. La columna **Gen name** especifica el gen afectado y **Position** señala la ubicación exacta del cambio dentro del genoma, de acuerdo con la anotación generada por *Prokka*. A su vez, **Strand** identifica la hebra del ADN en la que se

ENTREGA 2: Clasificación Taxonómica, Variantes, Anotación y Variantes de Interés

presenta la mutación y **Feature** describe la región funcional impactada, evidenciando que todas las variantes seleccionadas ocurren en CDS, es decir, regiones codificantes que dan lugar a proteínas.

Las columnas **REF** y **ALT** muestran los nucleótidos originales y los sustituidos, mientras que **Variant type** clasifica el tipo de alteración; en las variantes de impacto moderado, todas corresponden a mutaciones **MISSENSE**, las cuales sustituyen un codón por otro y generan el cambio de un aminoácido en la proteína, lo que se refleja directamente en la columna **Base change** y en **Aminoacid change**, donde se evidencia la consecuencia del cambio tanto en la secuencia del ADN como en la proteína resultante. Finalmente, **Function** describe el rol biológico conocido del gen afectado, permitiendo inferir las posibles consecuencias funcionales de cada variante.

Por otra parte, si se realizara una clasificación simplificada de las variantes de alto impacto presentes en la **tabla 4**, estas no pueden catalogarse como **MISSENSE** ni **SILENT**, sino que se agrupan funcionalmente dentro de la categoría de mutaciones disruptivas, ya que tanto las variantes **frameshift (INDELs)** como las **stop_lost** generan una alteración severa en la estructura de la proteína. En ambos casos, el resultado más probable es la formación de proteínas inestables o no funcionales, lo que coincide con su clasificación como variantes **HIGH impact** por parte de **SnpEff**.

Tabla 4. Variantes con alto impacto, después de los filtros aplicados. Selección de las 5 variantes con mayor calidad. **Elaborado por:** Sofía Betancur Álvarez.

HIGH IMPACT VARIANTS											
Variant	SEQ ID	Gen name	Position	Strand	Feature	BASE		Variant type	Base change	Aminoacid change	Function
						REF	ALT				
1	NODE_107_length_13797_cov_5.578009	allB_1	2593 (1540 - 2595)	+	CDS	T	A	stop_lost & splice_region_variant	c.1054T>A	p.Ter352Lysext*?	allantoinase monomer
2	NODE_1_length_82810_cov_6.073543	cdh_1	32937 (32503 - 32937)	+	CDS	A	T	stop_lost & splice_region_variant	c.435A>T	p.Ter145Cysext*?	CDP-diglyceride hydrolase / CDP-diacylglycerol pyrophosphatase
3	NODE_4_length_78117_cov_6.396019	mdoH_2	66445 (66444 - 68414)	-	CDS	T	A	stop_lost & splice_region_variant	c.1970A>T	p.Ter657Leuext*?	membrane glycosyltransferase%3 B synthesis of membrane-derived oligosaccharide (MDO)
4	NODE_37_length_31816_cov_6.374327	malT_2	3527 (3471 - 5063)	+	CDS	T	TG	Frameshift variant (INDEL)	c.1536_1537insC	p.Lys513fs	MalT transcriptional activator
5	NODE_42_length_28626_cov_6.073816	ygiM	26064 (26648 - 27268)	+	CDS	ANNNNNNNNNNN	A	Frameshift variant (INDEL)	c.333_342delNNNNNNNNNN	p.???111fs	putative signal transduction protein (SH3 domain)

La primera variante identificada corresponde al gen *allB_1*, localizado en el scaffold NODE_107, en la posición 2593 del genoma. Esta mutación consiste en un cambio de base de timina a adenina en la posición 1054 de la secuencia codificante, la cual según la anotación de **SnpEff**, produce una sustitución en el codón de parada (stop codon), cambiando el residuo de terminación (Ter) en la posición 352 por lisina (Lys) extendiendo así la traducción y por ende, la cola de aminoácidos termina más allá de esta posición hasta encontrar otro codon de parada (ext*). También, **SnpEff** indica que la variante ocurre en un sitio de corte y splicing, lo cual no tiene un significado biológico debido a que las bacterias no presentan un splicing convencional. Esta anotación se debe a que **SnpEff** fue diseñada inicialmente para genomas eucariotas, por ende, anota estos efectos de las variantes por defecto (Cingolani et al., 2012).

El gen *allB_1* es un pseudogen, el cual estructuralmente se asemeja a un gen pero no codifica una proteína, probablemente debido a que ha perdido su capacidad para hacerlo por mutaciones acumuladas a lo largo de la evolución (National Human Genome Research Institute [NIH], 2025a). Por otro lado, el gen funcional *allB* en *E. coli*, codifica la allantoinasa (ALLB), una hidrolasa que cataliza la conversión de allantoin a allantoato (UniProt, s.f.a), participando así en una ruta metabólica en la que se aprovecha la alantoína como

ENTREGA 2: Clasificación Taxonómica, Variantes, Anotación y Variantes de Interés

fuentes alternativas de nitrógeno en ausencia de oxígeno para incorporarlo a la síntesis de biomoléculas de la bacteria (Rodionova et al., 2023). Es por esto que, la pérdida de codón de parada posiblemente altera el plegamiento, estabilidad y actividad enzimática de la proteína, perdiendo su función y por ende, impidiendo la utilización de esa vía metabólica cuando sea requerida en situaciones de escasez de N_2 o anaerobiosis.

La segunda variante de alto impacto se localiza en el gen *cdh_1*, dentro del scaffold NODE_1, posición 32503, y consiste en un cambio de base A a T. De acuerdo con la anotación de *SnpEff*, se clasifica como la pérdida de un codón de parada y se encuentra en la región de splicing, siendo esta última una anotación nuevamente por defecto. La pérdida del codón de terminación en la posición 145 hizo que el aminoácido terminal fuera reemplazado por Cisteína (Cys) generando una proteína con una extensión C-terminal anómala. El gen afectado, *cdh*, codifica la hidrolasa CDP-diacilglicerol pirofosfatasa, la cual cataliza la hidrólisis del CDP-diacilglicerol a fosfatidato y CMP (UniProt, s.f.b). En *E. coli*, esta reacción es clave para regular la disponibilidad de precursores lipídicos que participan en la biosíntesis de fosfatidilglicerol y cardiolipina, componentes esenciales de la membrana celular bacteriana (Raetz & Dowhan, 1990). Dado que los lípidos de membrana son fundamentales para la integridad, permeabilidad y anclaje de proteínas, esta variante del gen (*cdh_1*) podría afectar la fisiología celular, la respuesta al estrés o la resistencia antimicrobiana, debido a que alteraciones en los componentes de la membrana externa como lipopolisacáridos pueden modificar la entrada de antimicrobianos, lo que es una de las bases de resistencia, o sensibilidad aumentada, en bacterias Gram-negativas (Goltermann et al., 2022).

La tercera variante corresponde al gen *mdoH_2*, ubicado en el scaffold NODE_4 en la posición 66445. El cambio de nucleótido implicó una sustitución de una adenina por timina, produciendo una variante tipo pérdida de codón y región de splicing (esta última, por defecto). En consecuencia, el codón de terminación en el residuo 657 es reemplazado por un codón para leucina (leu), lo cual origina una proteína más larga y anómala. El gen *mdoH* codifica una glucosiltransferasa de membrana involucrada en la síntesis de oligosacáridos derivados de membrana (MDOs), también conocidos como glucanos periplásmicos osmorregulados (OPGs) (UniProt, s.f.c). Estos compuestos son esenciales en bacterias Gram negativas, pues regulan la presión osmótica periplásmica, la integridad estructural de la envoltura celular y la respuesta a estrés ambiental (Bontemps et al., 2017), por ende, la variante puede afectar la síntesis correcta de OPGs, alterando la homeostasis osmótica y posiblemente aumentar o disminuir de la permeabilidad a moléculas.

Por otro lado, el gen *malT_2*, en el cual se identifica una inserción de una base adicional, se encuentra en el scaffold NODE_37. En la secuencia de referencia había originalmente un T y ahora hay TG, insertándose la G luego de la T, sin embargo, según la anotación de Human Genome Variation Society (HGVS), la mutación a nivel de ADN codificante equivale a una inserción de una C, refiriéndose a la hebra opuesta (Hart et al., 2024). El tipo de variante representa un frameshift (fs), lo que implica un desplazamiento del marco de lectura a partir del aminoácido 513 de lisina (Lys). Debido a esto, todos los codones posteriores se traducen incorrectamente, lo que conduce a una proteína posiblemente no funcional.

El gen implicado (*malT*) codifica la proteína MalT, la cual es un activador transcripcional para la regulación del operón maltosa en *E. coli*, induciendo la expresión de genes implicados en el transporte y catabolismo de maltosa y maltodextrina (Schlegel et al., 2002). Esta inserción puede resultar en la inactivación del regulador transcripcional, bloqueando la expresión de genes del operón y perder la capacidad para metabolizar maltosa; además, MalT controla la expresión de la porina LamB, una proteína de membrana que participa en la entrada de maltosa y el transporte de antibióticos (Choi & Lee, 2019). Es por esto que, esta variante, podría comprometer tanto el metabolismo energético de *E. coli* como la regulación de porinas, afectando la respuesta frente a antimicrobianos.

ENTREGA 2: Clasificación Taxonómica, Variantes, Anotación y Variantes de Interés

La quinta variante se encuentra en el gen *ygiM*, ubicado dentro del scaffold NODE_42_length_28626_cov_6.073816, en la posición 26064, afectando una región CDS en la hebra positiva. Este cambio corresponde a una delección/inserción múltiple de nucleótidos (INDEL), donde la secuencia original se reemplaza por una adenina, provocando un desplazamiento del marco de lectura (frameshift). La notación estándar utilizada para este cambio, es la forma completa de una delección de diez nucleótidos (los diez nucleótidos que van de c.333 a c.342) y este tipo de alteración modifica completamente la secuencia de aminoácidos desde el punto de la mutación, generando una traducción errónea y una proteína con pérdida estructural, en este caso anotada como p.???111fs, donde la notación "fs" (frameshift) confirma que la secuencia de aminoácidos cambia por completo a partir del aminoácido 111, propiciando la aparición de codones distintos y una probable terminación anticipada.

Si bien, de acuerdo a UniProt, la proteína producida por el gen es “*Uncharacterized protein YgiM*” (UniProt,s.f.d), el reporte de *Prokka* permite evidencias que el gen *ygiM* codifica una proteína putativa de transducción de señales que contiene un dominio SH3 (Sec Homology 3), y este es una región altamente conservada en bacterias que está asociado a la regulación de interacciones proteína-proteína y procesos de respuesta celular en bacterias (Mayer & Eck, 1995). Por lo tanto, esta variante implica una alteración que puede inactivar la función regulatoria del dominio SH3, comprometiendo mecanismos de transducción de señales y adaptabilidad bacteriana (Li, 2005). Dado el impacto funcional crítico del frameshift, esta variante se considera altamente crítica y consistente con la categoría *HIGH* impact asignada por *SnpEff*.

Tabla 5. Variantes con impacto moderado, después de los filtros aplicados. Selección de las 5 variantes con mayor calidad. *Elaborado por: Andrea Arredondo Restrepo.*

MODERATE IMPACT VARIANTS											
Variant	SEQ ID	Gen name	Position	Strand	Feature	BASE		Variant type	Base change	Aminocid change	Function
						REF	ALT				
1	NODE_1_length_82810_cov_6.073542	fieF	29147 (29042 - 29944)	+	CDS	G	T	Missense	c.106G>T	p.Ala36Ser	Zn2+ / Fe2+ / Cd2+ efflux transporter FieF
2	NODE_1_length_82810_cov_6.073542	glpX	37231 (37142 - 38152)	-	CDS	G	T	Missense variant	c.922C>A	p.Leu308Ile	fructose 1,6-bisphosphatase II
3	NODE_1_length_82810_cov_6.073542	ptsA	65016 (62918 - 65419)	-	CDS	C	A	Missense variant	c.404G>T	p.Ser135Ile	fused predicted PTS enzymes: HPr component / enzyme I component / enzyme IIA component
4	NODE_1_length_82810_cov_6.073542	pflC	69965 (69456 - 70334)	-	CDS	A	T	Missense variant	c.510A>T	p.Glu170Asp	putative pyruvate formate lyase 2 activating enzyme
5	NODE_1_length_82810_cov_6.073542	yjiO	71126 (70664 - 71515)	-	CDS	T	A	Missense variant	c.390A>T	p.Lys130Asn	putative DNA-binding transcriptional regulator

En cuanto al análisis particular de las variantes, la 1 corresponde al gen *fieF*, el cual se encuentra en la posición 2904-29944 del genoma, tiene como función la codificación de la proteína FieF o YjiP cuya trabajo es el transporte de cationes metálicos divalentes desde el interior de la célula al exterior, y su residuo es Zn₂, Cd₂ y Fe₂, ayudando a la homeostasis del hierro y la desintoxicación celular (NIH, 2025b), se ubica en la hebra sentido 5' - 3' del ADN ancestral, y en la secuencia evolucionada ocurre el cambio de una guanina por una timina en la posición 2917 del genoma y 106 de la base nitrogenada dentro de la secuencia codificante expresada como c, dando como resultado el cambio de Alanina por Serina en la posición 36 de la proteína, pudiendo alterar su función.

La variante 2 es el gen *glpX* que está en la posición 37142 – 38142, ubicado en la hebra 3' - 5', y su mutación se encuentra en el nucleótido 922 en donde se cambia una guanina por una timina, sustituyendo en la proteína leucina por isoleucina en la locación 308. La función del gen es catalizar la hidrólisis de la fructuosa 1,6-bisfosfato a fructosa 6-fosfato, esta es una reacción fundamental para la gluconeogénesis (Uniprot, s.f.e).

ENTREGA 2: Clasificación Taxonómica, Variantes, Anotación y Variantes de Interés

A su vez, la variante 3 corresponde al gen *ptsA* ubicado en la hebra complementaria en la posición 62918 – 65419, el cuál presenta una mutación (posición 65016 del genoma evolucionado) en la proteína de transferencia de multifosforilo PTS putativa PtsA (NIH, 2025c), debido al cambio de un ácido glutámico por isoleucina en la ubicación 135 de la molécula proteica, el cuál corresponde a un cambio de la base 404, sustituyendo citocina por adenina. Este gen está involucrado en el sistema de transporte de fosfotransferasa, el cual es un mecanismo para captar y fosforilar azúcares, introduciéndolos desde el medio externo y usando fosfoenolpiruvato como fuente de energía (DeCS, 2015).

La variante 4 es el gen *pflC*, el cual participa en la activación de la piruvato formiato-liasa 2 en condiciones anaerobias a través de la generación de un radical libre y utilizando como cofactor la S-adenosilmetionina para formar el radical libre 5'-desoxi-adenosina que activa la enzima y queda lista para catalizar la reacción del piruvato (Uniprot, s.f.f). Es esencial para el metabolismo energético en la fermentación anaerobia (Bedoya et al, 2007). Se encuentra en la posición 69456-70334 del ADN de la muestra ancestro, y la mutación ocurre en 69965, en donde se cambia la base adenina por una timina en la base 510, produciendo la mutación del ácido glutámico por ácido aspártico en la posición 170 de la proteína.

La quinta variante se localiza en el gen *yjjO*, dentro del scaffold NODE_1, en la posición 71126, afectando igualmente una región CDS, pero en la hebra negativa. Este cambio consiste en la sustitución de una timina por una adenina (T->A), donde el codón afectado provoca la substitución del aminoácido Lisina (Lys) por Asparagina (Asn) en la posición 130 (p.Lys130Asn). La lisina es un aminoácido básico con carga positiva a pH fisiológico, mientras que la asparagina es neutra y polar, por lo que esta sustitución puede modificar propiedades clave de interacción electrostática, estabilidad estructural o reconocimiento molecular (Maloy, 2013). El gen *yjjO* se ha descrito como un regulador transcripcional putativo (UniProt, s.f.g) con capacidad de unión al ADN, motivo por el cual una alteración puede producir cambios en la eficiencia regulatoria, sin eliminar completamente la función proteica (Dunnen & Antonarakis, 2000). Esto coincide con su clasificación como variante de impacto moderado, dado que la proteína aún se sintetiza pero con un potencial efecto en regulación génica, la respuesta metabólica y la adaptación del microorganismo a cambios ambientales.

REFERENCIAS

- Ardlie, K. G., & Guigó, R. (2017). Data Resources for Human Functional Genomics. *Current Opinion in Systems Biology*, 1, 75–79. <https://doi.org/10.1016/j.coisb.2016.12.019>
- Bedoya, A., Castrillón, J., Ramírez, J., Vásquez, J. & Zabala, M. (2007). Producción biológica de hidrógeno: una aproximación al estado del arte. *Scielo.org*. <http://www.scielo.org.co/pdf/dyna/v75n154/a14v75n154.pdf>
- Bontemps-Gallo S, Bohin J. & Lacroix J. (2017) Osmoregulated Periplasmic Glucans. *EcoSal Plua. Jun;7(2):10.1128/ecosalplus.ESP-0001-2017*. doi: 10.1128/ecosalplus.ESP-0001-2017. PMID: 28593831; PMCID: PMC11575687.
- Bracken. (s/f). Jhu.edu. <https://ccb.jhu.edu/software/bracken>
- Choi , U. & Lee, C. (2019) Distinct Roles of Outer Membrane Porins in Antibiotic Resistance and Membrane Integrity in *Escherichia coli*. *Frontiers in Microbiology*. doi: 10.3389/fmicb.2019.00953. PMID: 31114568; PMCID: PMC6503746
- Cingolani, P. (s.f.). Input & Output files. Input & output files - SnpEff & SnpSift. <https://pcingola.github.io/SnpEff/snpEff/inputoutput/#impact-prediction>
- Cingolani, P., Platts, A., Wang, L. L., Coon, M., Nguyen, T., Wang, L., Land, S. J., Lu, X., & Ruden, D. M. (2012). A program for annotating and predicting the effects of single nucleotide polymorphisms, SnpEff. *Fly*, 6(2), 80–92. <https://doi.org/10.4161/fly.19695>
- DeCs. (2015). Sistema de Fosfotransferasa de Azúcar del Fosfoenolpiruvato. DeCS/MeSH. <https://decs.bvsalud.org/es/ths/resource/?id=21047#:~:text=Es%20el%20sistema%20de%20fosfotransferasa,trav%C3%A9s%20de%20la%20membrana%20bacteriana.>

ENTREGA 2: Clasificación Taxonómica, Variantes, Anotación y Variantes de Interés

Dunnen, J. T., & Antonarakis, S. E. (2000). Mutation nomenclature extensions and suggestions to describe complex mutations: A discussion. *Human Mutation*, 15(1), 7–12. [https://doi.org/10.1002/\(sici\)1098-1004\(200001\)15:1<aid-humu4>3.0.co;2-n](https://doi.org/10.1002/(sici)1098-1004(200001)15:1<aid-humu4>3.0.co;2-n)

Goltermann L, Zhang M, Ebbensgaard AE, Fiodorovaite M, Yavari N, Løbner-Olesen A, Nielsen PE. Effects of LPS Composition in *Escherichia coli* on Antibacterial Activity and Bacterial Uptake of Antisense Peptide-PNA Conjugates. *Front Microbiol.* 2022 Jun 20;13:877377. doi: 10.3389/fmicb.2022.877377. PMID: 35794919; PMCID: PMC9251361.

Hart, R., Fokkema, I., DiStefano, M., Hastings, R., Laros, J., Taylor, R., Wagner, A. & Dunnen, J. (2024) Nomenclatura HGVS 2024: mejoras en la participación de la comunidad, usabilidad y computabilidad. *Genome Med* 16, 149. <https://doi.org/10.1186/s13073-024-01421-5>

ICTV. (s/f). Ictv.Global. <https://ictv.global/about/code>

Khan Academy. (s.f.). Types of mutations and their notations. Khan Academy. <https://www.khanacademy.org/test-prep/mcat/biomolecules/genetic-mutations/a/types-of-mutations-and-their-notations>

Koskella, B., & Brockhurst, M. A. (2014). Bacteria-phage coevolution as a driver of ecological and evolutionary processes in microbial communities. *FEMS Microbiology Reviews*, 38(5), 916–931. <https://doi.org/10.1111/1574-6976.12072>

Li, S. S.-C. (2005). Specificity and versatility of SH3 and other proline-recognition domains: Structural basis and implications for cellular signal transduction. *Biochemical Journal*, 390(3), 641–653. <https://doi.org/10.1042/bj20050411>

Maloy, S. (2013). Amino acids. *Brenner's Encyclopedia of Genetics*, 108–110. <https://doi.org/10.1016/b978-0-12-374984-0.00051-6>

Mayer, B., & Eck, M. (1995). SH3 domains: Minding your P's and Q's. *Current Biology*, 5(4), 364–367. [https://doi.org/10.1016/s0960-9822\(95\)00073-x](https://doi.org/10.1016/s0960-9822(95)00073-x)

National Human Genome Research Institute [NIH]. (2025a). *Pseudogén*. [Pseudogén](#)

National Human Genome Research Institute [NIH]. (2025b). Exportador de fieF Zn(2+)/Fe(2+)/Cd(2+) [*Escherichia coli* str. K-12 substr. MG1655]. National Library of Medicine. <https://www.ncbi.nlm.nih.gov/gene/948413>

National Human Genome Research Institute [NIH]. (2025c). ptsA, supuesta proteína de transferencia multifosforilada PTS (*Escherichia coli* est. K-12 subst. MG1655). National Library of Medicine. <https://www.ncbi.nlm.nih.gov/gene/948437>

National Human Genome Research Institute [NIH]. (2025). Mutación con cambio de sentido. National Human Genome. <https://www.genome.gov/es/genetics-glossary/Mutacion-con-cambio-de-sentido#:~:text=Definici%C3%B3n,funci%C3%B3n%20de%20la%20prote%C3%ADna%20codificada.>

Ochman, H., & Jones, I. B. (2000). Evolutionary dynamics of full genome content in *Escherichia coli*. *The EMBO Journal*, 19(24), 6637–6643. <https://doi.org/10.1093/emboj/19.24.6637>

Pupo, G. M., Lan, R., & Reeves, P. R. (2000). Multiple independent origins of *Shigella* clones of *Escherichia coli* and convergent evolution of many of their characteristics. *Proceedings of the National Academy of Sciences of the United States of America*, 97(19), 10567–10572. <https://doi.org/10.1073/pnas.180094797>

Raetz, C. & Dowhan, W. (1990). *Biosynthesis and function of phospholipids in Escherichia coli*. *The Journal of Biological Chemistry*, 265(3), 1235–1238. [\(PDF\) Biosynthesis and function of phospholipids in Escherichia coli](#)

Rodionova, I.A., Hosseinnia, A., Kim, S., Goodacre, N., Zhang, L., Zhang, Z., Palsson, B., Uetz, P., Babu, M. & Saeir, M. (2023). *E. coli* allantoinase is activated by the downstream metabolic enzyme, glycerate kinase, and stabilizes the putative allantoin transporter by direct binding. *Scientific Reports* 13, 7345. <https://doi.org/10.1038/s41598-023-31812-4>

Salter, S. J., Cox, M. J., Turek, E. M., Calus, S. T., Cookson, W. O., Moffatt, M. F., Turner, P., Parkhill, J., Loman, N. J., & Walker, A. W. (2014). Reagent and laboratory contamination can critically impact sequence-based microbiome analyses. *BMC Biology*, 12, 87. <https://doi.org/10.1186/s12915-014-0087-z>

Schlegel, A., Böhm, A., Lee, S.-J., Peist, R., Decker, K., & Boos, W. (2002). *Network regulation of the Escherichia coli maltose system*. *Journal of Molecular Microbiology and Biotechnology*, 4(3), 301–307. [Network regulation of the Escherichia coli maltose system - PubMed](#)

ENTREGA 2: Clasificación Taxonómica, Variantes, Anotación y Variantes de Interés

Turner, D., Shkoporov, A. N., Lood, C., Millard, A. D., Dutilh, B. E., Alfenas-Zerbini, P., van Zyl, L. J., Aziz, R. K., Oksanen, H. M., Poranen, M. M., Kropinski, A. M., Barylski, J., Brister, J. R., Chavisvili, N., Edwards, R. A., Enault, F., Gillis, A., Knezevic, P., Krupovic, M., ... Adriaenssens, E. M. (2023). Abolishment of morphology-based taxa and change to binomial species names: 2022 taxonomy update of the ICTV bacterial viruses subcommittee. *Archives of Virology*, 168(2), 74. <https://doi.org/10.1007/s00705-022-05694-2>

UniProt. (s.f.a). ALLB_ECOLI. UniProt. [allB - Allantoinase - Escherichia coli \(strain K12\) | UniProtKB | UniProt](#)

UniProt. (s.f.b). CDH_ECOLI. UniProt. [cdh - CDP-diacylglycerol pyrophosphatase - Escherichia coli \(strain K12\) | UniProtKB | UniProt](#)

UniProt. (s.f.c). OPGH_ECOLI. UniProt. [mdoH - Glucans biosynthesis glucosyltransferase H - Escherichia coli \(strain K12\) | UniProtKB | UniProt](#)

UniProt. (s.f.d). YGIM_ECOLI. UniProt. <https://www.uniprot.org/uniprotkb/P0ADT8/entry>

UniProt. (s.f.e). GLPX_ECOLI. UniProt. <https://www.uniprot.org/uniprotkb/P0A9C9/entry>

UniProt. (s.f.f). PFLC_ECOLI. UniProt. <https://www.uniprot.org/uniprotkb/P32675/entry>

UniProt. (s.f.g). YIJO_ECOLI. UniProt. <https://www.uniprot.org/uniprotkb/P32677/entry#function>

Wagner, E. F., Auer, B., & Schweiger, M. (1983). *Escherichia coli* virus T1: genetic controls during virus infection. *Current Topics in Microbiology and Immunology*, 102, 131–152. https://doi.org/10.1007/978-3-642-68906-2_4

Wood, D. E., & Salzberg, S. L. (2014). Kraken: ultrafast metagenomic sequence classification using exact alignments. *Genome Biology*, 15(3), R46. <https://doi.org/10.1186/gb-2014-15-3-r46>