

ENTREGA 3: Ortología y Filogenia

Presentado por: Andrea Arredondo Restrepo, Sofía Betancur Álvarez, Mariana Gutiérrez Tamayo, María José Montoya Cuartas.

Grupo: Bioamigas.

1. Gen seleccionado.

Para esta entrega del proyecto, se seleccionó el gen *gyrA* de *Escherichia coli* con el fin de identificar sus ortólogos en otras especies bacterianas, realizar un alineamiento múltiple y construir un árbol filogenético. Este análisis permitirá evaluar su conservación evolutiva y las posibles divergencias funcionales entre organismos. El gen *gyrA* fue elegido por ser una de las secuencias más conservadas en *E. coli* y en diversas especies bacterianas.

El gen *gyrA* codifica la subunidad A de la ADN girasa, una topoisomerasa de tipo II bacteriana. Esta enzima es la encargada de introducir superenrollamientos negativos en el ADN circular de doble cadena, la cual es una actividad importante para procesos celulares como la replicación, la transcripción, la recombinación y la compactación del ADN. La subunidad A, junto con la subunidad B (codificada por el gen *gyrB*), conforma el complejo funcional de la ADN girasa. Ambas subunidades trabajan de forma conjunta utilizando el ATP como fuente de energía para romper transitoriamente ambas hebras del ADN, permitir el paso de un segmento de la doble hélice a través de la ruptura y, posteriormente, religarlas, restaurando así la integridad de la molécula. (UniProt, s/f)

Adicionalmente, *gyrA* posee una alta relevancia clínica y evolutiva. Las mutaciones puntuales en su región central, denominada Región Determinante de la Resistencia a Quinolonas (QRDR), han sido ampliamente asociadas con el desarrollo de resistencia a los antibióticos del tipo fluoroquinolonas. Estos fármacos se utilizan para tratar una gran variedad de infecciones (incluyendo las del tracto urinario, el torrente sanguíneo y las entéricas); sin embargo, su uso desmedido ha llevado a que bacterias gramnegativas, como *E. coli*, desarrollen resistencia a estos compuestos, cuya diana molecular principal es precisamente la ADN girasa (Pourahmad Jaktaji & Mohiti, 2010). Por lo tanto, el estudio de este gen resulta interesante para comprender su papel en la evolución bacteriana, aparición de mecanismos de resistencia y análisis filogenéticos comparativos.

2. Introducción.

El análisis de ortología y filogenética permite comprender la historia evolutiva de los genes y su relación entre diferentes organismos. Los genes ortólogos y parálogos son dos tipos de genes homólogos que comparten un origen común, pero difieren en como surgieron y en sus funciones evolutivas. Por un lado, los genes ortólogos son aquellos que se encuentran en diferentes especies y se derivan de un mismo gen ancestral tras un evento de especiación, es decir, cuando una especie se divide en dos especies diferentes y por lo general estos genes son similares en cuanto a secuencia y mantienen la misma función en las diferentes especies, permitiendo así su uso para estudios filogenéticos y clasificación taxonómica de los organismos (Biology LibreTexts, 2017).

Por otro lado, los genes parálogos son genes que se encuentran dentro de una misma especie como resultado de duplicaciones génicas, y sus funciones pueden cambiar con el tiempo. Estos genes se originan por la duplicación de un gen dentro del genoma, pudiendo adquirir así nuevas funciones o especializaciones. Entender la diferencia entre ambos tipos de genes es fundamental para interpretar correctamente árboles filogenéticos y establecer las relaciones evolutivas reales entre secuencias (Biology LibreTexts, 2017).

ENTREGA 3: Ortolología y Filogenia

En la construcción de árboles filogenéticos es necesario incluir un grupo externo (*outgroup*), ya que proporciona un punto de referencia para interpretar las relaciones entre los organismos del estudio y permite el enraizamiento del árbol. Entonces, el grupo externo sirve para identificar la relación evolutiva entre los grupos internos (*ingroup*), es decir, los taxones que son el foco de análisis (Bartleby, 2021). Para su elección, se parte de la hipótesis de que el grupo externo comparte un ancestro común con el *ingroup*, pero que dicho ancestro es más antiguo que el ancestro común de los taxones del grupo interno. Esta relación es la que permite al *outgroup* funcionar como la raíz del árbol filogenético (Bartleby, 2021).

Así entonces, es fundamental seleccionar adecuadamente el grupo externo, ya que su elección puede afectar la topología del árbol resultante. Por ello, el *outgroup* debe cumplir dos condiciones principales: la primera es que no debe pertenecer al grupo interno, y la segunda es que debe estar lo suficientemente relacionado con él como para compartir rasgos básicos ancestrales, los cuales sirven como una referencia para inferir el estado original de los caracteres antes de la diversificación del *ingroup* (Bartleby, 2021).

Por otra parte, en la reconstrucción de árboles filogenéticos existen dos enfoques principales para analizar los datos. Uno de ellos es el enfoque frecuentista, el cual se basa en encontrar el árbol que mejor explica los datos observados sin utilizar información previa, ya que considera la probabilidad como la frecuencia con la que ocurre un evento si el experimento se repitiera muchas veces. En este enfoque se emplean métodos como el de máxima verosimilitud para estimar el árbol más probable, y se aplican técnicas como el bootstrap para evaluar el nivel de confianza en cada rama. Sin embargo, los valores de bootstrap obtenidos no representan la probabilidad real de que un clado sea verdadero, sino la frecuencia con que dicho clado aparece al repetir el análisis con diferentes muestras de datos (Huelsenbeck & Rannala, 2004).

El enfoque bayesiano por su parte incorpora tanto los datos observados, como la información previa conocida sobre cómo podrían ser los árboles o los parámetros evolutivos. Con este enfoque, se calcula la probabilidad de cada árbol posible, considerando tanto los datos del estudio como la información previa disponible, obteniendo como resultado una distribución de probabilidad que indica qué tan probable es cada árbol. En este caso, a diferencia del enfoque frecuentista, los valores de soporte obtenidos sí pueden interpretarse directamente como la probabilidad de que un clado sea correcto, bajo el modelo y la información previa utilizada (Huelsenbeck & Rannala, 2004).

3. Metodología.

Luego de seleccionar *gyrA* como gen de interés, se obtuvo su secuencia de nucleótidos desde la base de datos del NCBI, para a partir de ahí continuar con la búsqueda de ortólogos. Inicialmente, dicha búsqueda comenzó desde la interfaz en línea de BLAST, sin embargo, durante el proceso, los resultados mostraron que todas las secuencias encontradas tenían valores de Query Cover y Percent Identity iguales al 100%, indicando una aparente no presencia de genes ortólogos. Si bien en la búsqueda se espera observar un alto porcentaje de cobertura para garantizar que la mayor parte de la secuencia este alineada, la identidad se espera menor al 100% para reflejar divergencia evolutiva (González-Pech et al., 2018). Por esta razón, los resultados con identidad y cobertura absolutos fueron descartados, ya que no aportaban divergencia y representaban secuencias redundantes que no permitirían encontrar variabilidad en los análisis posteriores.

Tomando en cuenta lo anterior, se descargó el programa local de BLAST y se intentó un ajuste de parámetros que permitiera encontrar ortólogos, pero dicho ajuste no fue logrado porque la configuración utilizada fue muy astringente y poco flexible y se seguían obteniendo resultados con valores de 100% en

ENTREGA 3: Ortología y Filogenia

los atributos ya mencionados. Así entonces, ¿Por qué hay que manejar parámetros de BLAST flexibles? La respuesta se encuentra en que la herramienta compara secuencias de nucleótidos o proteínas con grandes bases de datos de secuencias y calcula el nivel de significancia estadística de las coincidencias, para devolver los resultados con atributos como las cobertura, porcentaje de identidad máximo, valor-E, porcentaje de identidad máxima, la puntuación máxima y la puntuación total, entre otros (Eser et al., 2014).

Sin embargo, aunque el algoritmo es altamente eficiente en la identificación de homólogos, puede llegar a ser demasiado estricto y restrictivo para la identificación de secuencias divergentes. Esto se debe a la configuración por defecto utilizada por BLAST, donde se prioriza una alta similitud en las secuencias y un menor tiempo de cómputo sobre la detección de homólogos distantes, tendiendo así a su omisión. Esta limitación plantea un reto en los análisis de divergencia donde el principal objetivo es la búsqueda de ortólogos (González-Pech et al., 2018). Así entonces, se hace enserio aumentar la precisión a la hora de configurar los parámetros de corrida de BLAST, incluyendo ajustes más permisivos y flexibles que mejoren la capacidad del algoritmo para encontrar ortólogos lejanos (Widmann et al., 2006).

Como alternativa a la alta sensibilidad requerida en la parametrización de BLAST, se encontró una herramienta alternativa llamada OrthoDB, la cual es una base de datos para la búsqueda de ortólogos ligada al NCBI. Desde allí, se descargó el grupo de secuencias ortólogas para *gyrA* a nivel de Bacteria y se almacenó en un archivo *.fasta* al cual con la herramienta *seqkit* se le realizó una depuración para eliminar secuencias repetidas y tomar únicamente 200 secuencias seleccionadas de manera aleatoria (Para más información sobre el proceso de limpieza y depuración consultar en el repositorio de GitHub el archivo README). Además, en el archivo filtrado y limpio, se incluyó la *query sequence* del gen *gyrA* en *Escherichia coli str. K-12* y el *outgroup*, que fue la secuencia del mismo gen en la arquea *Haloferax volcanii* DS2.

Después se utilizó el programa MAFFT de manera local para realizar el alineamiento y obtener el archivo de salida, el cual se visualizó en Aliview para verificar el proceso. Con ese mismo archivo, se realizó la construcción del árbol filogénico en IQTREE y se visualizó con la herramienta ITol.

4. Modelo de sustitución.

Cuando se comparan secuencias homologas de ADN, es posible observar que algunos nucleótidos han cambiado con el tiempo y cada uno de estos cambios es llamado sustitución. De esta manera, dependiendo de la naturaleza química de las bases, pueden ocurrir dos tipo de sustituciones de nucleótidos. Se tiene entonces, que la transición (*Ti*) es donde no hay cambio de clase química y la sustitución es dentro de la misma clase, es decir, son del tipo *purina* ↔ *purina* o *pirimidina* ↔ *pirimidina*. Por otra parte, la transversión (*Tv*) se da cuando hay un paso entre diferentes clases y son del tipo *purina* ↔ *pirimidina* (Foster, 2013). Los dos mecanismos de cambios en la secuencia del ADN que ocurren a nivel biológico se muestran en la **figura 1**.




Figura 1. Mecanismos de sustitución a nivel de secuencia del ADN. Tomado de: <https://doi.org/10.1016/B978-0-12-374984-0.00139-X>

ENTREGA 3: Ortología y Filogenia

Estos mecanismos toman especial relevancia cuando se habla a nivel bioinformático, pues sirven como indicadores para la construcción de diversos modelos de sustitución, los cuales representan los eventos de sustitución matemáticamente, asignando diferentes tasas y mediciones a los mecanismos de cambio para reflejar sus probabilidades biológicas. Entonces, una de las métricas más relevantes para el modelado es el ratio de transición vs transversión denotado como (Ti/Tv) (Duchêne et al., 2015). De esta manera los mecanismos de sustitución vistos a nivel de secuencia son los cambios de base observados, mientras que a nivel de modelado son parámetros que permiten describir que tan probables son los cambios ocurridos.

En este caso, para el alineamiento con MAFFT se seleccionó el modelo `GTR + F + I + R7` y esta información se puede verificar en la sección `best fit model` del archivo `.fasta.log` obtenido después de la ejecución de la herramienta. A continuación, se presenta una descripción de cada una de las partes del modelo utilizado, teniendo en cuenta que la base es el modelo GTR y los demás son componentes añadidos para hacerlo más flexible y realista.

(Lanave et al., 1984) y (Rodríguez et al., 1990) han demostrado que el modelo GTR es un proceso estacionario de Markov mediante el cual las probabilidades de sustitución entre los nucleótidos se expresan en forma de una matriz $P(t)$. El modelo GTR asume que las frecuencias de caracteres de equilibrio y las probabilidades de transición instantánea permanecen constantes a lo largo del tiempo. Entonces, la dinámica de las probabilidades de sustitución para un tiempo infinitesimal dt se describe por:

$$P(t + dt) = P(t)(I + Rdt)$$

Donde I y R son matrices reales de cuatro por cuatro que representan, respectivamente, la matriz de identidad y la matriz de tasa de sustitución instantánea (es decir, las probabilidades de sustitución instantánea entre los cuatro nucleótidos).

El modelo GTR, General Time Reversible por sus siglas en inglés, es el modelo más general y usado en el modelado de sustituciones para la evolución de secuencias de ADN. Su base parte de que la evolución es reversible y que, por ejemplo, la tasa de cambios $A \rightarrow G$ es proporcional a la tasa $G \rightarrow A$. Además, a cada uno de los posibles casos de sustitución se les asigna su propia tasa paramétrica de probabilidad (Sumner et al., 2012 & Kimura, 1980). Dicha tasa, es posible consultarla en el documento `.fasta.log` obtenido en la sección `Rate parameters`. En la **tabla 1** se presenta entonces la tasa para cada posible tipo de sustitución. El tipo de sustitución más probable en el alineamiento corresponde al cambio $C \leftrightarrow T$ (transición), con una tasa de 4.18691, mientras que el cambio menos probable es $G \leftrightarrow T$ (transversión), con una tasa de 1.00000. Este patrón indica que las transiciones ocurren con mayor frecuencia que las transversiones.

Tabla 1. Tasa paramétrica de probabilidad asociada a cada posible caso de sustitución. Construida a partir del archivo `.fasta.log` arrojado por MAFFT. **Elaborado por:** Mariana Gutiérrez Tamayo.

Posible sustitución	Tasa
$A \leftrightarrow C$	1.99060
$A \leftrightarrow G$	3.34296
$A \leftrightarrow T$	3.07577
$C \leftrightarrow G$	3.38564
$C \leftrightarrow T$	4.15249
$G \leftrightarrow T$	1.00000

ENTREGA 3: Ortología y Filogenia

Por otra parte, el complemento +F indica que IQTREE utilizó frecuencias de bases observadas durante el alineamiento en lugar de asumir proporciones iguales de $\frac{1}{4}$ (0.25) para cada tipo de base, lo cual hace el modelo más realista debido a que en el ADN la composición de cada base rara vez es igual (Gatto et al., 2006). Esta información puede igualmente consultarse en el archivo *.fasta.log* en la sección *base frequencies*. La composición de cada base se presenta en la **tabla 2**, donde es posible observar que la base con mayor composición son G Y C con 28.3% y 26.1% respectivamente, lo cual sugiere una tendencia a un contenido rico en regiones G-C.

Tabla 2. Frecuencia de composición de cada base dentro del ADN. Construida a partir del archivo *.fasta.log* arrojado por MAFFT. **Elaborado por:** Mariana Gutiérrez Tamayo.

Base	Frecuencia
A	0.251
C	0.261
G	0.283
T	0.205

En cuanto al termino +I, este explica el hecho de que algunos sitios son invariables, debido a una fuerte restricción selectiva como es el caso de algunos codones esenciales (Shapiro et al., 2005). Dentro del archivo de reporte generado por MAFFT "*alineamiento_concatenado_final2.fasta.log*" se encuentra como *proportion of invariable sites* y para este caso muestra que alrededor del 1.7% de las posiciones de evolución son evolutivamente invariables.

Finalmente, la extensión +R7 representa que IQTREE utilizó el modelo FreeRate con 7 categorías de tasa. Este se utiliza cuando los datos no siguen una distribución gama de probabilidad y es una alternativa no paramétrica que complementa el modelo GTR al modelar la velocidad de evolución a través de 7 sitios diferentes en el alineamiento, considerando que todos tienen diferentes velocidades (Gatto et al., 2006 & Zou et al., 2024). La información arrojada se encuentra en la sección *site proportion and rates* y sigue la forma $R_i(P_i, r_i)$ donde R_i es la categoría, P_i la proporción de sitios y r_i la tasa relativa con $i=1, 2, \dots, 7$. Los resultados obtenidos del alineamiento, se muestran en la **tabla 3**, donde se observa que aproximadamente el 4,4% de los sitios de evolucionan muy lento con una tasa relativa de 0.035, mientras que acerca del 23.8% lo hace rápidamente con una tasa del 1.847, evidenciando que a mayor velocidad de evolución, se tiene una mayor tasa.

Tabla 3. Proporción de sitios y sus tasas relativas que explican la velocidad de evolución de cada sitio. Construida a partir del archivo *.fasta.log* arrojado por MAFFT. **Elaborado por:** Mariana Gutiérrez Tamayo.

R_i	(P_i, r_i)
1	(0.042, 0.034)
2	(0.052, 0.124)
3	(0.083, 0.262)
4	(0.119, 0.483)
5	(0.196, 0.793)
6	(0.238, 1.245)
7	(0.253, 1.823)

ENTREGA 3: Ortología y Filogenia

Finalmente, a modo de resumen, en la tabla 4 se presenta la función de cada parte del modelo seleccionado por IQTREE, GTR+F+I+R7 que se entiende como modelo General Time Reversible (GTR) con frecuencias diferentes para cada base, sitios invariables y 7 categorías FreeRate.

Tabla 4. Proporción de sitios y sus tasas relativas que explican la velocidad de evolución de cada sitio. Construida a partir del archivo *.fasta.log* arrojado por MAFFT. **Elaborado por:** Mariana Gutiérrez Tamayo.

Componente	Implicación dentro del modelo
GTR	Cada tipo de sustitución tiene su propia tasa paramétrica que indica la probabilidad de ocurrencia. Captura la tasa de transiciones vs transversiones. Modela los procesos de mutación.
+F	Modela las frecuencias de cada base, tomando que difieren del 0.25 y que no tienen proporciones iguales.
+I	Modela las regiones altamente conservadas debido a que algunos sitios nunca cambian.
+R7	Los diferentes sitios tomados por el programa evolucionan con diferente velocidad y tasas relativas.

5. Árbol filogenético.

• Análisis evolutivo.

El árbol filogenético construido a partir de las secuencias ortólogas al gen *gyrA* de *E. coli* (ver en el pdf adjunto), muestra la relación evolutiva a través de una estructura por ramas, que permiten entender y representan su historia de evolución. Los puntos de unión denominados nodos indican los ancestros comunes, y las líneas (ramas) representan la cantidad de divergencia o cambio genético que ha pasado desde el ancestro.

Al analizar los resultados obtenidos es posible notar una gran diversidad de especies bacterianas, las cuales pueden ser agrupadas por sus filos o linajes evolutivos. Por ejemplo, *Rhizobium*, *Pantoea*, *Xenorhabdus*, *Pseudomonas* y *Vibrio* pertenecen a las Proteobacterias (Lumen learning, s.f.), mientras que *Streptomyces*, *Micromonospora* y *Mycobacterium* corresponden al filo Actinobacteria (Barka et al., 2015); *Bacillus* y *Paenibacillus* al filo Firmicutes (Quimica.es, s.f.), y *Flavobacterium*, *Dyadobacter* y *Hymenobacter* se ubican dentro del filo Bacteroidota (Pan et al., 2023). Estas separaciones confirman que hubo un buen alineamiento de las secuencias y el modelo evolutivo logra representar las sustituciones y divisiones que a lo largo del tiempo el gen *gyrA* ha tenido.

El filo de las Proteobacterias forma clados compactos con ramas cortas entre sus miembros. Este grupo conformado por especies como *Pantoea coffeiphila*, *Xenorhabdus ehlersii*, *Pseudomonas jinjuensis* y *Vibrio profundus*, muestra una pequeña distancia evolutiva respecto a la secuencia guía de *E. coli*, e indica que tienen una alta conservación del gen, su estructura y funcionalidad, con amplias similitudes entre sus secuencias. A su vez, éstas tienen pocas sustituciones respecto a *E. coli*, y su nodo de unión es reciente, lo que indica que comparten un ancestro en común cercano. En contraste, el filo más alejado es el Bacteroidota (en especial estas especies: *Hymenobacter*, *Flavobacterium* y *Elizabethkingia*), el cuál presenta ramas más largas y distancias mayores a la secuencia guía; reflejando una mayor divergencia genética y un ancestro en común más alejado.

Por otro lado, si bien dentro del árbol se evidencian especies más cercanas o distantes a *E. coli*, es importante no olvidar que el hecho de que todas las secuencias analizadas se agrupen en el mismo árbol

ENTREGA 3: Ortología y Filogenia

filogenético confirma la homología funcional del gen, la cual codifica una enzima esencial para la replicación bacteriana. Es posible concluir entonces, que las distancias evolutivas mayores muestran una adaptación de las bacterias a lo largo del tiempo, pero la conservación global del **gyrA** indica el mismo rol biológico, y confirma que son ortólogos funcionales a la secuencia de *E. coli*.

- **Ortología y validación funcional.**

El análisis filogenético del gen **gyrA** permitió conocer y confirmar la ortología entre las 200 secuencias evaluadas; ya que todas se agrupan dentro del mismo árbol genético, y a pesar de que algunos filos y especies presentan mayor afinidad y cercanía ancestral, el árbol muestra como de un ancestro en común ha variado el gen a través de distintos linajes. Lo que indica que el **gyrA** es altamente conservado y esencial para la replicación bacteriana.

Las distancias evolutivas cortas entre *E. coli* y otras especies como *Pantoea coffeiphila*, son prueba de su relación ortóloga reciente, y reflejan la similitud de los nucleótidos en las secuencias. Por el contrario, las distancias mayores entre las Bacteroidotas o las Actinobacterias con la secuencia de referencia, evidencian mayor divergencia, pero sin pérdida en la funcionalidad del gen, ya que este gen es conservado en todas las bacterias y las secuencias ortólogas mantienen los dominios y funciones similares, a pesar de su lejanía evolutiva (Biology LibreTexts, s.f.).

En conclusión, el análisis del árbol filogenético confirma que el gen **gyrA** ha cambiado a lo largo de la evolución de los filos, presentando divergencias, su conservación estructural y funcional confirma que las secuencias analizadas son ortólogas a la de *E. coli*.

- **Comparación con el árbol de especies**

Para comparar el árbol filogenético del gen **gyrA** (figura 2), se construyó también el árbol de especies (figura 3) a partir de la información taxonómica de las mismas especies incluidas en el análisis del gen utilizando la herramienta NCBI Common Tree disponible en *Taxonomy Browser* del National Center for Biotechnology Information (NCBI). Para ello, se introdujeron los nombres científicos de las aproximadamente 200 especies analizadas y se generó el árbol en formato .phy, que posteriormente fue visualizado en iTOL para su comparación con el árbol filogenético obtenido mediante IQ-TREE. Este análisis proporciona una referencia que representa las relaciones evolutivas reconocidas entre las especies, permitiendo evaluar la congruencia o incongruencia entre la filogenia taxonómica y la evolución del gen **gyrA**.

Esta comparación permite evaluar si la evolución de este gen refleja la forma clásica y fundamental de la herencia mediante transferencia genética vertical, es decir, de una generación a la siguiente o si, por el contrario, ha experimentado eventos de incongruencia filogenética debido a la transferencia horizontal de genes. Dado que **gyrA** codifica la subunidad A de la ADN girasa, una enzima esencial involucrada en el superenrollamiento del ADN bacteriano, se espera que su secuencia esté altamente conservada entre especies relacionadas. Sin embargo, las presiones selectivas asociadas al uso de antibióticos fluoroquinolonas pueden generar mutaciones adaptativas que alteren su patrón evolutivo, provocando discrepancias respecto al árbol de especies (Yoshida et al., 1990; Abby et al., 2012).

ENTREGA 3: Ortología y Filogenia




Figura 2 y 3. Visualización en iTOL del árbol filogenético del gen *gyrA* y el árbol de especies del mismo, respectivamente. **Nota:** Para visualizar completamente el árbol e interactuar con este, dar click en la figura correspondiente.


El árbol de especies obtenido presenta una estructura coherente con la taxonomía bacteriana, en la cual los principales géneros y familias se agrupan de forma esperada, puesto que hacen relación a la evolución general de las especies documentada en NCBI. En contraste, el árbol filogenético construido a partir del gen *gyrA*, presenta diferencias en la topología de los clados al ser más dispersa y heterogénea. En este árbol, las especies pertenecientes a un mismo género no siempre aparecen agrupadas y, en varios casos, se observan asociaciones inesperadas entre bacterias taxonómicamente distantes.

Al realizar la comparación visual entre ambos árboles mediante iTOL, se aprecia que en el árbol de especies géneros como *Helicobacter* y *Paenibacillus* forman clados que mantienen una estructura congruente con la evolución esperada del linaje (Tabla 5). Sin embargo, en el árbol del gen *gyrA*, géneros como *Helicobacter*, presentan una incongruencia topológica, es decir, existe un patrón de ramificación diferente, de igual forma, *Paenibacillus* presenta clados mezclados con otras especies y ancestros comunes diferentes, lo que evidencia una pérdida parcial de coherencia taxonómica y grupos polifiléticos. Estos patrones de incongruencia sugieren que la historia evolutiva del gen *gyrA* no sigue exactamente la misma trayectoria que la evolución de las especies que lo tienen, posiblemente debido a procesos genéticos y evolutivos diferentes (Philippe et al., 2011).

Por otro lado, la presencia de especies no emparentadas que comparten secuencias similares de *gyrA* sugiere posibles eventos de transferencia horizontal de genes, fenómeno común en bacterias como mecanismo adaptativo frente a presiones ambientales o antimicrobianas. Dichos eventos explican que el árbol del gen *gyrA* muestre agrupamientos de especies de diferentes géneros, rompiendo la congruencia con el árbol de especies. La transferencia horizontal de genes es uno de los mecanismos evolutivos más importantes en bacterias, y ocurre cuando un organismo adquiere material genético de otro sin ser su descendiente directo. A diferencia de la herencia donde los genes se transmiten de una generación a la siguiente, la transferencia horizontal permite el intercambio de información genética entre especies no relacionadas, contribuyendo a la rápida diversificación y adaptación bacteriana (Soucy et al., 2015).

ENTREGA 3: Ortología y Filogenia

Tabla 5. Análisis visual de las diferencias evolutivas de los géneros *Helicobacter* y *Paenibacillus* respecto a ambos árboles filogenéticos.

Árbol filogenético del gen <i>gyrA</i>	Árbol filogenético de especies
Género: <i>Helicobacter</i>	
 - Helicobacter sp. 11-8110 CCY98 RS00745 - Helicobacter ceterum C6H25 RS07795 - Helicobacter anseris CQA57 RS06555 - Helicobacter saguini LS64 RS09350	 "Helicobacter ceterum" "Helicobacter anseris" "Helicobacter saguini" "Helicobacter sp. 11-8110"
Género: <i>Paenibacillus</i>	
 - Clostridium oryzae CLORY RS12775 - Paenibacillus sp. Soil750 ASL11 RS24600 - Shouchella ionarensis BLT29 RS04120 - Macrococcus hajekii ERX37 RS03030 - Anaerolactobacter massiliensis C7E00 RS10205 - Salinicoccus sediminis WN59 RS02230 - Cytobacillus massiliagabonensis C1726 RS15755 - Puniceicoccaceae bacterium GN221 RS04825 - Effusibacillus pohliae DSM 22757 C230 RS0107410 - Paenibacillus sophorae BMX71 RS22350 - Paenibacillus elgii AV654 RS14060 - Paenibacillus sp. A3 QJ48 RS19470 - NC 013967.1 1443314-1445902	 "Paenibacillus elgii" "Paenibacillus sophorae" "Paenibacillus sp." "Paenibacillus sp. Soil750"

Debido al papel funcional del gen y a las presiones selectivas ejercidas por el uso extensivo de estos antibióticos, las variantes de *gyrA* que confieren resistencia pueden ser movilizadas entre diferentes linajes bacterianos a través de, por ejemplo, plásmidos. Esto provoca que secuencias altamente similares del gen aparezcan en especies filogenéticamente distantes, generando clados intercalados y pérdida de congruencia con el árbol de especies. Así, el patrón de agrupamientos incongruentes observado en el árbol del gen *gyrA* podría reflejar esta dinámica de transferencia de genes, la cual genera una historia evolutiva diferente y similar a una red.

Ahora bien, según el archivo de salida de **IQ-TREE** correspondiente al análisis, se detectaron numerosos sitios con alto porcentaje de *gaps* y advertencias en la prueba de composición. Esto indica que las secuencias del gen *gyrA* no se encuentran perfectamente alineadas, probablemente por la inclusión de fragmentos incompletos o por la alta variabilidad en ciertas regiones. Cuando esto ocurre, los algoritmos de inferencia filogenética pierden precisión, generando agrupamientos con bajo soporte estadístico (Philippe et al., 2011). Es por esto que también, visualmente, se identifican ramas mucho más largas y relaciones topológicas menos coherentes en el árbol de *gyrA*, en comparación con el árbol de especies.

• Análisis funcional

Por otro lado, es importante destacar que la comparación de árboles construidos a partir de múltiples genes ortólogos es una herramienta que podría ser útil en otros análisis, ya que es fundamental para comprender con mayor precisión la historia evolutiva de los organismos. A diferencia de los análisis basados en un solo gen, que pueden reflejar únicamente la historia particular de ese locus, la comparación entre varios genes ortólogos (filogenómica) permite distinguir también diferencias asociadas a la evolución conservada y a eventos de transferencia horizontal, duplicación o pérdida génica (Gabaldón & Koonin, 2013). Esto, permite identificar genes que mantienen patrones filogenéticos congruentes y

ENTREGA 3: Ortología y Filogenia

aquellos que muestran divergencias notables, lo que sugiere presiones selectivas específicas o historia evolutiva independiente.

En este sentido, comparar los árboles filogenéticos de distintos genes ortólogos, como *gyrA*, *recA*, *rpoB* o *dnaK*, permite inferir cuáles regiones del genoma son altamente conservadas y cuáles han sido más propensas a procesos de transferencia genética. Los genes con topologías congruentes tienden a formar parte de las secuencias conservadas asociadas con funciones esenciales y estables en el tiempo, mientras que los genes incongruentes suelen localizarse en regiones móviles del genoma, vinculadas con adaptación ecológica, patogenicidad o resistencia antimicrobiana (Ravenhall et al., 2015). En otro contexto, este tipo de análisis resultaría crucial para distinguir diferencias evolutivas que son especialmente frecuentes en procariotas.

Asimismo, es útil la construcción de árboles de consenso a partir de múltiples genes constituye una estrategia robusta para sintetizar la información filogenética y minimizar la influencia de anomalías o sesgos individuales. Los árboles de consenso combinan las topologías derivadas de distintos genes para producir una filogenia promedio o general, que representa las relaciones evolutivas más estables entre los linajes (Bryant, 2003). De esta manera, se reducen los efectos de incongruencias locales causadas por errores de alineamiento, tasas de sustitución heterogéneas o eventos de transferencia horizontal. En términos prácticos, un árbol de consenso refleja la señal filogenética global del genoma, integrando tanto las regiones conservadas como las divergentes.

REFERENCIAS

- Barka, E., Vatsa, P., Sanchez, L., Gaveau, N., Jacquard, C., Klenk, H., Clément, C., Oudouch, Y. & Van Wezel, G. (2015). Taxonomía, fisiología y productos naturales de las *actinobacterias*. *Microbioly and molecular biology reviews*, 1(1), 1-43. <https://doi.org/10.1128/mmbr.00019-15>
- Bartleby. (2021). *Outgroups are significant in studying cladistics or phylogenetics (that describe the evolutionary relationship between different organisms). Further, it is also important to understand the differences and similarities between different organisms.* Bartleby.com. <https://www.bartleby.com/subject/science/biology/concepts/outgroups>
- Bryant, D. (2003). *A classification of consensus methods for phylogenetics*. DIMACS Series in Discrete Mathematics and Theoretical Computer Science. [A classification of consensus methods for phylogenetics](#)
- Duchêne, S., Ho, S.Y. & Holmes, E.C. Declining transition/transversion ratios through time reveal limitations to the accuracy of nucleotide substitution models. *BMC Evol Biol* 15, 36 (2015). <https://doi.org/10.1186/s12862-015-0312-6>
- Eser, E., Can, T., & Ferhatosmanoğlu, H. (2014). Div-Blast: Diversification of sequence search results. *PLoS ONE*, 9(12). <https://doi.org/10.1371/journal.pone.0115445>
- Foster, P. L. (2013). Base substitution mutations. *Brenner's Encyclopedia of Genetics*, 300. <https://doi.org/10.1016/b978-0-12-374984-0.00139-x>
- Gabaldón, T. & Koonin, E. (2013) Functional and evolutionary implications of gene orthology. *Nat Rev Genet* 14, 360–366. <https://doi.org/10.1038/nrg3456>
- Gatto, L., Catanzaro, D., & Milinkovitch, M. C. (2006). Assessing the applicability of the GTR nucleotide substitution model through simulations. *Evolutionary Bioinformatics*, 2. <https://doi.org/10.1177/117693430600200020>
- González-Pech, R. A., Stephens, T. G., & Chan, C. X. (2018). Commonly misunderstood parameters of NCBI BLAST and important considerations for users. *Bioinformatics*, 35(15), 2697–2698. <https://doi.org/10.1093/bioinformatics/bty1018>

ENTREGA 3: Ortología y Filogenia

- Huelsenbeck, J., & Rannala, B. (2004). Frequentist properties of Bayesian posterior probabilities of phylogenetic trees under simple and complex substitution models. *Systematic Biology*, 53(6), 904–913. <https://doi.org/10.1080/10635150490522629>
- Kimura, M. A simple method for estimating evolutionary rates of base substitutions through comparative studies of nucleotide sequences. *J Mol Evol* 16, 111–120 (1980). <https://doi.org/10.1007/BF01731581>
- Lanave C., Preparata G., Saccone C., and Serio G., 1984. A new method for calculating evolutionary substitution rates., *J. Mol. Evol.*, 20(1): 86–93. Google Scholar
- LibreTexts. (s.f.). *Homólogos, ortólogos y parálogos*. LibreTexts. [https://bio.libretexts.org/Bookshelves/Microbiology/Microbiology_\(Boundless\)/07%3A_Microbial_Genetics/7.13%3A_Bioinformatics/7.13C%3A_Homologs_Orthologs_and_Paralogs#:~:text=Orthologous%20are%20homologous%20genes%20where,in%20sequence%20composition%20and%20function.](https://bio.libretexts.org/Bookshelves/Microbiology/Microbiology_(Boundless)/07%3A_Microbial_Genetics/7.13%3A_Bioinformatics/7.13C%3A_Homologs_Orthologs_and_Paralogs#:~:text=Orthologous%20are%20homologous%20genes%20where,in%20sequence%20composition%20and%20function.)
- Lumen learning. (s.f.). *Proteobacteria*. Lumen learning. <https://courses.lumenlearning.com/suny-microbiology/chapter/proteobacteria/#:~:text=Dentro%20del%20g%C3%A9nero%20Helicobacter%2C%20la,el%20punto%20de%20vista%20cl%C3%ADnico>
- Pan, X., Raajimakers, J. & Carrió, V. (2023). Importance of Bacteroidetes in host–microbe interactions and ecosystem functioning. *Trends in microbiology*, 31(9), 959–971. <https://doi.org/10.1016/j.tim.2023.03.018>
- Philippe, H. et al. (2011). *Resolving difficult phylogenetic questions: why more sequences are not enough*. PLoS Biology, 9(3) <https://doi.org/10.1371/journal.pbio.1000602>
- Pourahmad Jaktaji, R., & Mohiti, E. (2010). Study of Mutations in the DNA gyrase gyrA Gene of Escherichia coli. *Iranian Journal of Pharmaceutical Research: IJPR*, 9(1), 43–48.
- Quimica.es. (s.f.). *Firmicutes*. Quimica.es. <https://www.quimica.es/enciclopedia/Firmicutes.html>
- Ravenhall, M., Škunca, N., Lassalle, F., & Dessimoz, C. (2015). *Inferring horizontal gene transfer*. PLoS Computational Biology, 11(5) <https://doi.org/10.1371/journal.pcbi.1004095>
- Rodriguez F., Oliver J. L., Marin A., and Medina J. R., 1990. The general stochastic model of nucleotide substitution, *Journal of Theoretical Biology*, 142: 485–501. Google Scholar
- S.S. Abby, E. Tannier, M. Gouy, & V. Daubin. (2012) Lateral gene transfer as a support for the tree of life, *Proc. Natl. Acad. Sci. U.S.A.* 109 (13) 4962–4967, <https://doi.org/10.1073/pnas.1116871109>
- Shapiro, B., Rambaut, A., & Drummond, A. J. (2005). Choosing appropriate substitution models for the phylogenetic analysis of protein-coding sequences. *Molecular Biology and Evolution*, 23(1), 7–9. <https://doi.org/10.1093/molbev/msj021>
- Soucy, S., Huang, J. & Gogarten, J. (2015) Horizontal gene transfer: building the web of life. *Nat Rev Genet* 16, 472–482 (2015). <https://doi.org/10.1038/nrg3962>
- Sumner, J. G., Jarvis, P. D., Fernández-Sánchez, J., Kaine, B. T., Woodhams, M. D., & Holland, B. R. (2012a). Is the general time-reversible model bad for molecular phylogenetics? *Systematic Biology*, 61(6), 1069–1074. <https://doi.org/10.1093/sysbio/sys042>
- UniProt. (s/f). *P0AES4 · GYRA_ECOLI*. UniProt. <https://www.uniprot.org/uniprotkb/P0AES4/entry>
- Widmann, J., Hamady, M., & Knight, R. (2006). DivergentSet, a tool for picking non-redundant sequences from large sequence collections. *Molecular & Cellular Proteomics*, 5(8), 1520–1532. <https://doi.org/10.1074/mcp.t600022-mcp200>

ENTREGA 3: Ortología y Filogenia

- Yoshida, H., Bogaki, M., Nakamura, M. & Nakamura, S. (1990) Quinolone resistance-determining region in the DNA gyrase *gyrA* gene of *Escherichia coli*. *Antimicrob Agents Chemother* 34. <https://doi.org/10.1128/aac.34.6.1271>
- Zou, Y., Zhang, Z., Zeng, Y., Hu, H., Hao, Y., Huang, S., & Li, B. (2024). Common methods for phylogenetic tree construction and their implementation in R. *Bioengineering*, 11(5), 480. <https://doi.org/10.3390/bioengineering11050480>